# 四 XTuner 微调 LLM



介绍了如何使用XTuner来微调大语言模型(LLM),详细讲解了增量预训练和指令微调两种方法,并且强调了数据标准 化和对话模板的添加的重要性。同时解释了进行微调的理由和详细的微调工作流程,并且介绍了XTuner框架的使用方法。以 下是内容的详细总结:

一、大语言模型微调理论与实践

强调了增量预训练和指令微调两种微调方法的重要性。

提到了数据的标准格式化和对话模板添加的必要性。

二、大模型微调工具箱X2

介绍了X2工具箱,强调其轻量级、易用性和对多种微调算法及硬件的支持。

解释了对话模板的作用和在训练中添加的起始符与结束符的意义。

### 三、使用X-Tuner工具加速训练

介绍了如何使用X-Tuner中的pk pro max length来提高GPU利用率。

提到了X Tuner内置的两种加速方式: flash attention和deep speed zero。

讲述了如何使用8GB显存的显卡微调1.8B模型。

### 四、多模态模型预测

详细介绍了如何使用文本和图像的多模态模型进行预测。

强调了模型训练和测试阶段的操作,以及使用高质量数据进行微调的重要性。

### 五、利用X推进行微调

详述了微调的步骤,包括准备开发机、安装环境、准备数据集和选择配置文件等。

### 六、使用BECULA PA13进行模型训练和转换

提供了完整的CONFIG文件和权重文件的信息。

讲解了如何进行对话测试和模型转换的步骤,包括将Pytorch模型转换为Huggingface格式,并解释了LoRA模型文件的概



## OpenMMLab Sili Sili

# 一条数据的一生

原始数据

标准格式数据

添加对话模板

Tokenized数据

添加 Label

开始训练

### 对话模板

对话模板是为了能够让 LLM 区分出, System、User 和 Assistant, 不同的模型会有不同的模板。

#### LlaMa 2

- · <</SYS>> System 上下文结束
- · <<SYS>> System 上下文开始
- [INST] User 指令开始
- [/INST] User 指令结束

#### InternLM2

- <|System|>: System 上下文开始
- < |User|>: User 指令开始
- <eoh>: End of Human, User 指令结束
- <|Bot|>: Assistant 开始回答
- <eoa>: End of Assistant, Assistant 回答结束

# 启动对话 System 你是一个安全的 AI 助手 User 输入 世界第一高峰是? 添加对话模板 Assistant 回复 (包含对话模板) 珠穆朗玛峰

#### LlaMa 2

[INST]<SYS>> 你是一个安全的 AI 助手 <>/SYS>>

[INST]«SYS» 你是一个安全的 AI 助手 «/SYS»

世界最高的峰是? [/INST]

[INST]<SYS>> 你是一个安全的 AI 助手 <>/SYS>>

世界最高的峰是? [/INST]珠穆朗玛峰

#### InternLM

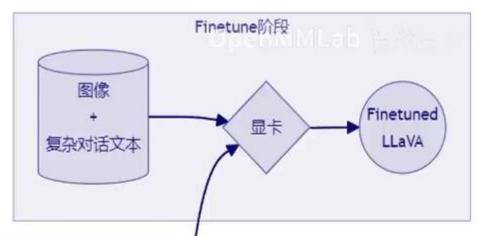
<|System|>: 你是一个安全的 AI 助手

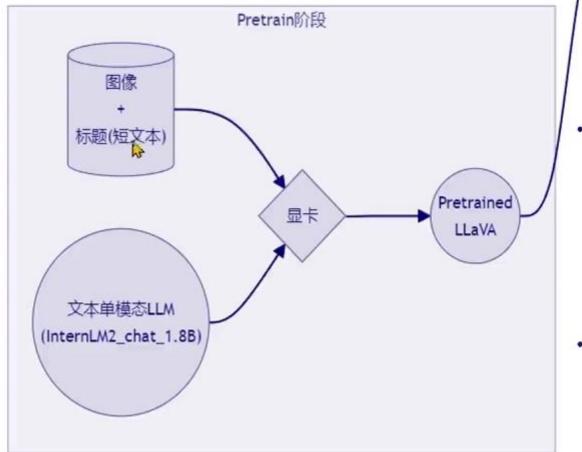
- (|System|>: 你是一个安全的 AI 助手
- (|User|>: 世界最高峰是什么峰? ‹eoh>
- «|Bot|»:
- <|System|>: 你是一个安全的 AI 助手
- 《|User|>: 世界最高峰是什么峰? ‹eoh>
- 《Bot》: 珠穆朗玛峰(eog)

# 快速上手

在本节中,我们将自己构造
<question
text><image>-<answer text> 数据对,
基于
InternLM2\_Chat\_1.8B这
个文本单模态模型,使用
LLaVA方案,训练一个给
InternLM2\_Chat\_1.8B使

用的Image Projector文件。





- · LLaVA方案中,给LLM增加视觉能力的过程,即是训练Image Projector文件的过程。
- · 该过程分为2个阶段:
  Pretrain和Finetune。

